

NVIDIA RUBIN: AI FACTORY, REDEFINED

2026年、AIコンピューティングは新たな次元へ



Blackwellの次、ではない。Blackwellの常識を覆す存在。

Blackwellの量産開始からわずか1年。NVIDIAはCES 2026でAIの経済性を根底から変える次世代プラットフォーム「Rubin」を発表。これは単なる性能向上ではなく、AIという「工場」の生産性革命である。

推論トークンコスト

最大1/10

推論性能 (vs. Blackwell)


5倍

学習性能 (vs. Blackwell)

3.5倍

飛躍の鍵は「Extreme Co-design（極端な協調設計）」

チップ設計の常識を破る。NVIDIAは6つの新チップ（Vera CPU, Rubin GPU, NVLink 6, ConnectX-9, BlueField-4, Spectrum-6）を個別に開発するのではなく、単一のスーパーコンピュータの部品として、ゼロから同時に再設計した。業界では「狂気」とも呼ばれるこのアプローチが、システム全体のボトルネックを排除する唯一の道だった。




Rubinプラットフォームを構成する6つの心臓部

コンピュータ、ネットワーキング、データ処理。AI工場のあらゆる要素がRubinのために再設計された。



Vera CPU

GPUへのデータ供給と
汎用処理を担う頭脳




Rubin GPU

AIの学習と推論を担うエンジン



NVLink 6 Switch

ラック内での超高速GPU間通信
(スケールアップ)




ConnectX-9 SuperNIC

ラック間での超広帯域通信
(スケールアウト)



BlueField-4 DPU

ネットワーク、ストレージ、
セキュリティのタスクをオフロード




Spectrum-6 Ethernet Switch

データセンター全体を繋ぐ
ファブリック


GPU性能の直接比較：世代間の圧倒的格差

HBM4メモリの全面採用と新アーキテクチャにより、演算性能とメモリ帯域幅が爆発的に向上。これはMoEモデルのような巨大モデルの学習・推論効率に直結する。



GPUを支える頭脳：Vera CPUの進化

AI性能はGPUだけでは決らない。カスタムArmコア「Olympus」を搭載したVera CPUが、大容量・広帯域のメモリ（LPDDR5X）を通じてデータを効率的に供給することで、システム全体のスループットを最大化する。



「システムこそがコンピュータ」：ラックスケールでの性能比較

個々のチップの性能向上は、システム全体で相乗効果を生む。72基のGPUを単一の巨大エンジンとして稼働させるVera Rubin NVL72は、AI工場の「トークン生産性」を桁違いに引き上げる。

項目	GB200 NVL72	Vera Rubin NVL72	性能向上率
NVFP4 推論	0.72 EFLOPS	3.6 EFLOPS	5倍
NVFP4 学習	0.71 EFLOPS	2.5 EFLOPS	3.5倍
CPUメモリ容量	21.6 TB	54 TB	2.5倍
GPUメモリ容量	13.8 TB	20.7 TB	1.5倍
HBM帯域幅	0.57 PB/s	1.6 PB/s	2.8倍
スケールアップ 帯域幅	130 TB/s	260 TB/s	2倍



独走を許さない挑戦者：AMDの逆襲「Helios」

NVIDIAの牙城に対し、AMDはラックスケールソリューション「Helios」で真っ向から勝負を挑む。次世代GPU「Instinct MI450/455X」を核に、メモリ容量とコスト効率を武器に、異なるアプローチでAIインフラの覇権を狙う。



頂上決戦：Vera Rubin NVL72 vs. Helios Rack


メモリ容量と帯域幅ではAMDが優位に立つ一方、FP4演算性能ではNVIDIAが圧倒的。ドルあたりの性能（perf/\$）ではAMDが優位性を主張。今後の勝敗は、AIのワークロードによって大きく左右される可能性がある。

比較項目	NVIDIA Vera Rubin NVL72	AMD Helios Rack (MI450)
GPU数	72基	72基
HBM4メモリ容量	~21 TB	31 TB
メモリ帯域幅	260 TB/s	1.4 PB/s
FP4演算性能	3,600 PFLOPS	~1,440 PFLOPS
\$/M Tokens (推定)	~\$0.50-0.80	~\$0.65-1.00

戦略の激突：垂直統合のNVIDIA vs. オープンエコシステムのAMD

NVIDIAはハードウェア（NVLink）とソフトウェア（CUDA）を固く連携させ、究極の性能を追求するクローズドな垂直統合モデル。対するAMDは、UALinkやUltra Ethernetといったオープン規格を推進し、パートナーと共に「NVIDIA包囲網」を形成する水平連携モデル。

垂直統合モデル（Closed Ecosystem）



水平連携モデル（Open Ecosystem）



エコシステムの力：主要プレイヤーは既にRubinを選択

AWS, Google Cloud, Microsoft Azure, Oracle Cloudの4大CSPに加え、Dell, HPE, Lenovo, Supermicroといった主要OEM、さらにRed Hat, Canonical, SUSEといったエンタープライズLinuxパートナーも即座にRubinへの対応を表明。このエコシステムの広さと対応の速さが、NVIDIAの最大の強みである。



チップの競争から「AI工場」の競争へ

「データセンターはもはやスーパーコンピュータではなく、
トークンを生み出すAI工場である」 - ジェンスン・フアン


重要なのは、個々のチップ性能ではなく、学習と推論のトークンをいかに効率的に、低コストで生み出すかという「工場全体の生産性」。NVIDIAとAMDの激しい競争が、その進化を加速させる。



要点サマリー



1. **飛躍:** Rubinは「Extreme Co-design」により、Blackwellを凌駕する性能と効率性を実現した。



2. **戦略転換:** NVIDIAの製品はチップ単体から、ラックスケールで最適化された統合システムへと移行した。



3. **対抗軸:** AMDのHeliosは強力な対抗馬であり、メモリ性能と「オープン戦略」で差別化を図る。



4. **未来:** 今後の覇権争いは、AIインフラ全体の「生産性」と「エコシステム」が焦点となる。

ゴールラインは、さらに先にある

Rubinは通過点に過ぎない。NVIDIAはすでに出発準備が整っているNVL144、そしてゴールラインであるNVL576を見据えている。エクサスケールの時代がすぐそこまで迫り、次なる目標はゼタスケールへ。

