


AIの信頼性を巡るパラダイムシフト

ハルシネーションの根本原因と、その対策

「より賢い推論」から「より正確な世界モデルの定義」へ



本日の問い

**LLMのハルシネーションを、
いかにして構造的に減らすか？**

幻覚の正体を再定義する



従来の考え方 (Conventional View)

LLMは事実を知らない、または論理的に間違えるから幻覚を起こす。



新しい視点 (The New Perspective)

LLMは、**明確に定義された問題モデルなしに推論する**から幻覚を起こす。

これは「推論 (Inferential) の失敗」ではなく、
「表現 (Representational) の失敗」である。


アジェンダ：信頼性への3つのステップ

- 
1.
第一幕：『思考』するAIの登場
推論モデルとCoTの功績と限界
 2.
第二幕：パラダイムシフト
Model-First Reasoning (MFR)の発見
 3.
未来へ：次なる地平
World-First Reasoningへの展望

第一幕：『思考』するAIの限界

最初の進歩：「思考」するAIとLong CoT


- OpenAIのo1/o3やDeepSeek-R1のような推論モデルは、回答の前に長く詳細な「思考の連鎖（Long Chain-of-Thought）」を生成する。
- この「思考してから回答する」アプローチにより、数学やコーディングのような複雑なタスクで性能が飛躍的に向上した。
- これは、より高度な推論能力への重要な第一歩であった。



CoT/ReActに潜む根本的な欠陥

CoTやReActは、「問題のモデル化」と「推論」を一つの生成プロセス内で同時に行う。


その結果、内部の問題モデルが**暗黙的かつ不安定 (implicit and unstable)**になり、以下の問題を引き起こす：



第二幕：パラダイムシフト

解決策：Model-First Reasoning (MFR)

「モデル構築」と「推論」を完全に分離する。



MFRフェーズ1：世界のルールを定義する

LLMはまず、問題空間を構成する要素を明示的にリストアップする。



Entities:

関係者、リソース、場所など



State Variables:

可用性、ステータスなど、時間と共に変化する特性



Actions:

許可される操作（その前提条件と効果を含む）



Constraints:

常に守るべきルール、不変条件


重要なルール：このフェーズでは、まだ解決策を生成しない。

MFRフェーズ2：定義された世界の中で推論する

モデルが確定したら、そのルールに厳密に従って計画を生成する。

- アクションは定義された前提条件を尊重する。
- 状態遷移は定義された効果と一致する。
- すべてのステップで制約が遵守される。

これにより、根拠のない仮定や論理の飛躍が構造的に防止され、すべてのステップが検証可能になる。



なぜMFRはハルシネーションを減らすのか：CoTとの比較

Feature	Chain-of-Thought (CoT)	Model-First Reasoning (MFR)
制約違反	Medium	Low
暗黙の仮定	Frequent	Rare
構造の明確さ	Low	High
根本原理	統計的な尤もらしさ (Statistical Plausibility)	構造的な正しさ (Structural Validity)

実装：プロンプトは驚くほどシンプル

MFRはアーキテクチャの変更や追加学習を必要とせず、プロンプトだけで実装可能。

フェーズ1：モデル構築

以下の問題を分析し、問題モデルを明示的に定義してください。

1. エンティティ：[登場人物、モノ、場所など]
2. 状態変数：[変化する可能性のある状態]
3. アクション：[可能な操作と、その前提条件・効果]
4. 制約：[守るべき絶対的なルール]

****注意：まだ解決策は提案しないでください。 ****

フェーズ2：推論

上記で定義したモデル「のみ」を使用して、ステップバイステップで解決策を生成してください。すべてのステップが制約を満たしていることを確認してください。

MFRの限界と考慮事項



トークン長の増加

モデル構築の分、プロンプトと出力が長くなる。



モデル構築の精度依存

フェーズ1のモデル定義が間違っていると、後続の推論も失敗する。




タスク適合性

医療スケジューリングや資源配分など、制約が多く構造化されたタスクで最も効果を発揮する。

未来へ：次なる地平


次の地平：World-First Reasoning

MFRは、推論「プロセス」を改善するアプローチである。




Stage 1
Chain-of-Thought

Answer



Stage 2
Model-First Reasoning



Stage 3
World-First Reasoning

「AIが嘘をつかないための**安全柵**」
を設置するアプローチ。

「そもそも嘘をつく余地がない**世界**を
先に作る」という、より大きな目標。

MFRは、この「世界モデルの固定」という究極の目標に向けた、実践的で重要な一歩である。

まとめ：ハルシネーションを構造的に減らすために

1. 問題の再定義

ハルシネーションの根本原因は、推論能力の欠如ではなく、**不安定な問題表現**にあると捉える。

2. プロセスの分離

推論の前に、まずLLM自身に**問題モデル（ルール、制約）**を明示的に定義させる。

3. モデル内で推論

定義されたモデルの**厳格な制約の中で**解決策を生成させ、論理の飛躍と捏造を防ぐ。

AIに正しく推論させるには、まず「世界」を正しく定義させよ。